

Examen_SistemasDistribuidos_Dask

June 26, 2019

EXAMEN SISTEMAS_DISTRIBUIDOS Integrantes: --Luna Morales Cinthia Selene --Zurita Barbosa Fernanda Izamar --Ortíz Pérez Víctor

```
In [1]: #Como primeros pasos se importaron las librerias indispensables
        #para la ejecución de cada uno de los apartados solicitados.
        import dask.dataframe as dd
        import pandas as pd
        import matplotlib.pyplot as plt
        from pyproj import Proj, transform
        from time import time
        from bokeh.models import BoxZoomTool
        from bokeh.plotting import figure, output_notebook, show
        from bokeh.tile_providers import STAMEN_TERRAIN

In [2]: #En primer lugar se define un dataframe de resultados que contiene
        #cada unos de los meses con los que se trabajarán y las columnas requeridas.
        df_resultados = pd.DataFrame(
            index=[1,2,3,4,5,6,7,8,9,10,11,12],
            columns = ['mes', 'mean_distance', 'tiempo_mean_distance',
                      'mean_time', 'tiempo_mean_time', 'viajes_largos',
                      'numero_taxis_diferentes', 'medallion_mas_viajes_largos',
                      'numero_viajes_max_medallion'])

In [3]: # leer todos los archivos de datos
        plantilla="trip_data_{}.csv"

        # En segundo lugar se realiza una conversión de datos en columnas
        # que se lograron identificar previamente para evitar errores
        # posteriores, de igual forma se generan nuevas columnas renombradas
        # de forma que no afecten ejecuciones siguientes, también
        # se identifican las que son necesarias para la creación del
        # dataframe de resultados mencionado con anterioridad y se eliminan
        # las no indispensables, además, se identifican si existen renglones
        # con errores en los datos, por ejemplo si hay columnas con
        # campos vacíos, de manera puntual en la columna identificada
        # con el nombre (passenger_count) que contiene el número de pasajeros
        # por taxi se realizó una limpieza de los datos tomando en cuenta solo
        # aquellos en donde el numero de pasajeros fuera menor a 4
```

```

# de acuerdo a la siguiente referencia https://www.anuevayork.com/los-taxis-en-nueva-y
# igualmente se eliminan datos de las columnas en pickup_longitude,
# pickup_latitude, dropoff_longitude, dropoff_latitude, que contienen
# las coordenadas de llevada y recogida donde solo se conservan las que
# se encuentren dentro del rango siguiente (-74.253842,-73.709271) y (40.495089,40.910

for mes in range (1,2):
    archivo = plantilla.format(mes)
    df = dd.read_csv(archivo, dtype={' store_and_fwd_flag': 'object', 'trip_time_in_secs'
    #print (archivo)
    new_columns=['medallion', 'hack_license', 'vendor_id', 'rate_code',
                'store_and_fwd_flag', 'pickup_datetime', 'dropoff_datetime',
                'passenger_count', 'trip_time_in_secs', 'trip_distance',
                'pickup_longitude', 'pickup_latitude', 'dropoff_longitude',
                'dropoff_latitude']
    df = df.rename(columns=dict(zip(df.columns, new_columns)))
    del df['store_and_fwd_flag']
    del df['rate_code']
    del df['vendor_id']
    del df['hack_license']
    df=df[(~df["medallion"].isnull()) & (~df["passenger_count"].isnull()) & (df["passenger_count"]>0)]

#{Propuesta}
# El flujo de trabajo que se propone en esta solución es el siguiente:
# Una vez descargados y descomprimidos los 12 archivos, se procede a una
# lectura de cada uno de ellos, calculando y guardando resultados de cada archivo.
# Para posteriormente trabajar con los resultados de los 12 archivos y generar la
# solución solicitada. Para esto se requirieron 3 archivos:
#
# 1. Dataframe de resultados
#     * mean_distance
#     * tiempo_mean_distance
#     * mean_time
#     * tiempo_mean_time
#     * viajes_largos
#     * numero_taxis_diferentes
#     * medallion_mas_viajes_largos
#     * medallion_mas_viajes
#     * numero_viajes_max_medallion
#
# 2. Dataframe para horas_día (que nos servirá para las gráficas por número de pasajeros)
#     * no_pasajeros
#     * pickup_datetime
#
# 3. Dataframe para medallion_mas_viajes (que nos servirá para las gráficas geográficas)
#     * mes
#     * medallion_mas_viajes
#     * pickup_longitude,

```

```

#         * pickup_latitude,
#         * dropoff_longitude,
#         * dropoff_latitude,
#         * pickup_datetime
#         * dropoff_datetime

# Cálculo del promedio de distancia y del tiempo que se tardó en hacerlo.
inicio = time()
mean_distance = df['trip_distance'].mean().compute()
fin = time()
tiempo_mean_distance = fin-inicio

# Cálculo del promedio de tiempo y del tiempo que se tardó en hacerlo.
inicio = time()
mean_time = df['trip_time_in_secs'].mean().compute()
fin = time()
tiempo_mean_time = fin-inicio

# Cálculo de la duración de viaje, diferencia con la proporcionada y cuales son vi
df['dropoff_datetime']=dd.to_datetime (df['dropoff_datetime'])
df['pickup_datetime']=dd.to_datetime (df['pickup_datetime'])
df['duracion']=(df['dropoff_datetime']-df['pickup_datetime']).dt.seconds
df['diferencia_tiempo']=df['duracion']-df['trip_time_in_secs']
df['viaje_largo'] = (df['trip_time_in_secs']>(60*20))
df.compute()

# La ejecución de código siguiente cuenta el numero de viajes largos en cada archi
df_vl=df[df.viaje_largo==True]
del df_vl['trip_time_in_secs']
del df_vl['trip_distance']
df_vl.compute()
viajes_largos=len(df_vl)

# De la columna generada identificada con el nombre viajes_largos se identifica
# el número de taxis diferentes (la columna medallion contiene un numero que
# identifica cada uno de los vehiculos). De lo anterior se obtiene ¿qué vehículos
# que mas viajes realizan en cada mes? y si son el mismo vehículo.
taxis_diferentes = df_vl.medallion.value_counts().compute()
numero_taxis_diferentes=len(taxis_diferentes)
medallion_mas_viajes_largos=taxis_diferentes.index[0]
numero_viajes_max_medallion = taxis_diferentes.max()
df_resultados.loc[mes] = [mes,mean_distance,tiempo_mean_distance,
                           mean_time,tiempo_mean_time,viajes_largos,
                           numero_taxis_diferentes,medallion_mas_viajes_largos,
                           numero_viajes_max_medallion]

# Para el dataframe horas_día y medallion_mas_viajes

```

```

# Si es el primer mes se crean los dataframes, sino se
# agregan al creado para Enero.
if (mes == 1):
    # Creación de df_medallion_mas_viajes
    df_medallion_mas_viajes=df_vl[(df_vl['medallion']==medallion_mas_viajes_largos)]
    del df_medallion_mas_viajes['passenger_count']
    del df_medallion_mas_viajes['duracion']
    del df_medallion_mas_viajes['diferencia_tiempo']
    del df_medallion_mas_viajes['viaje_largo']
    df_medallion_mas_viajes=df_medallion_mas_viajes.compute()

    # Creación de df_horas_dia
    df_horas_dia=df_vl
    del df_horas_dia['medallion']
    del df_horas_dia['dropoff_datetime']
    del df_horas_dia['pickup_longitude']
    del df_horas_dia['pickup_latitude']
    del df_horas_dia['dropoff_longitude']
    del df_horas_dia['dropoff_latitude']
    del df_horas_dia['duracion']
    del df_horas_dia['diferencia_tiempo']
    del df_horas_dia['viaje_largo']
    df_horas_dia=df_horas_dia.compute()
else:
    # Se agregan resultados del mes al df_medallion_mas_viajes
    medallion_mv=df_vl[(df_vl['medallion']==medallion_mas_viajes_largos)]
    del medallion_mv['passenger_count']
    del medallion_mv['duracion']
    del medallion_mv['diferencia_tiempo']
    del medallion_mv['viaje_largo']
    medallion_mv=medallion_mv.compute()
    df_medallion_mas_viajes=pd.concat([df_medallion_mas_viajes,medallion_mv])

    # Se agregan resultados del mes al df_horas_dia
    df_hd=df_vl
    del df_hd['medallion']
    del df_hd['dropoff_datetime']
    del df_hd['pickup_longitude']
    del df_hd['pickup_latitude']
    del df_hd['dropoff_longitude']
    del df_hd['dropoff_latitude']
    del df_hd['duracion']
    del df_hd['diferencia_tiempo']
    del df_hd['viaje_largo']
    df_hd=df_hd.compute()
    df_horas_dia=pd.concat([df_horas_dia,df_hd])
df_resultados
# La respuesta fue obtenida ejecutando el código siguiente:

```

```
Out [3]:
```

| | mes | mean_distance | tiempo_mean_distance | mean_time | tiempo_mean_time | \ |
|----|-----|---------------|----------------------|-----------|------------------|---|
| 1 | 1 | 2.76352 | 62.1418 | 683.093 | 63.6953 | |
| 2 | NaN | NaN | NaN | NaN | NaN | |
| 3 | NaN | NaN | NaN | NaN | NaN | |
| 4 | NaN | NaN | NaN | NaN | NaN | |
| 5 | NaN | NaN | NaN | NaN | NaN | |
| 6 | NaN | NaN | NaN | NaN | NaN | |
| 7 | NaN | NaN | NaN | NaN | NaN | |
| 8 | NaN | NaN | NaN | NaN | NaN | |
| 9 | NaN | NaN | NaN | NaN | NaN | |
| 10 | NaN | NaN | NaN | NaN | NaN | |
| 11 | NaN | NaN | NaN | NaN | NaN | |
| 12 | NaN | NaN | NaN | NaN | NaN | |

| | viajes_largos | numero_taxis_diferentes | medallion_mas_viajes_largos | \ |
|----|---------------|-------------------------|----------------------------------|---|
| 1 | 1488329 | 13101 | DAF57CF25F00457CC6077CD628EC71AC | |
| 2 | NaN | NaN | NaN | |
| 3 | NaN | NaN | NaN | |
| 4 | NaN | NaN | NaN | |
| 5 | NaN | NaN | NaN | |
| 6 | NaN | NaN | NaN | |
| 7 | NaN | NaN | NaN | |
| 8 | NaN | NaN | NaN | |
| 9 | NaN | NaN | NaN | |
| 10 | NaN | NaN | NaN | |
| 11 | NaN | NaN | NaN | |
| 12 | NaN | NaN | NaN | |

| | numero_viajes_max_medallion |
|----|-----------------------------|
| 1 | 266 |
| 2 | NaN |
| 3 | NaN |
| 4 | NaN |
| 5 | NaN |
| 6 | NaN |
| 7 | NaN |
| 8 | NaN |
| 9 | NaN |
| 10 | NaN |
| 11 | NaN |
| 12 | NaN |

```
In [6]: # En la siguiente ejecución se indica el tiempo que tarda en obtener
# el promedio de la distancia de viaje (trip_distance) de
# al dataframe creado de resultados df_resultados
```

```
# Cálculo del promedio de distancia y tiempo que se tardó en hacerlo para los 12 archi
inicio = time()
```

```

mean_distance_total = df_resultados['mean_distance'].mean()
fin = time()
tiempo_mean_distance_total = fin-inicio + df_resultados['tiempo_mean_distance'].sum()

# En la siguiente ejecución se indica el tiempo que tarda en obtener
# el promedio de la distancia de viaje (trip_distance) de
# al dataframe creado de resultados df_resultados

# Cálculo del promedio de tiempo y tiempo que se tardó en hacerlo para los 12 archivos
inicio = time()
mean_time_total = df_resultados['mean_time'].mean()
fin = time()
tiempo_mean_time_total = fin-inicio + df_resultados['tiempo_mean_time'].sum()

# En la siguiente ejecución se indica el número de viajes
# largos de al dataframe creado de resultados df_resultados
viajes_largos_total = df_resultados['viajes_largos'].sum()

print ("El tiempo en segundos que se tardó en calcular el promedio de la distancia pa
print ("El tiempo en segundos que se tardó en calcular el promedio de tiempo para los
print ("En el año se realizaron ", viajes_largos_total, " viajes mayores a 20 minutos.

```

El tiempo en segundos que se tardó en calcular el promedio de la distancia para los 12 archivos
El tiempo en segundos que se tardó en calcular el promedio de tiempo para los 12 archivos es:
En el año se realizaron 1488329 viajes mayores a 20 minutos.


In [7]: # La siguiente ejecución genera una gráfica temporal del número total de pasajeros, ag

```

df_horas_dia["dia_del_anio"] = df_horas_dia["pickup_datetime"].dt.dayofyear
dia_anio = df_horas_dia.groupby('dia_del_anio')
resultado_pasajeros_dia = dia_anio.passenger_count.mean()
resultado_pasajeros_dia = resultado_pasajeros_dia
resultado_pasajeros_dia = resultado_pasajeros_dia.sort_index()
resultado_pasajeros_dia.plot.line(style="--*", figsize=(25,15), color="green")
plt.ylabel("Número_de_pasajeros")

```

Out[7]: Text(0, 0.5, 'Número_de_pasajeros')



Se puede notar que de acuerdo a la gráfica anual obtenida anteriormente se puede notar que los picos en los que existen un número mayor de pasajeros corresponden a los días festivos de los Estados Unidos:


--Existe un incremento de pasajeros a principios del mes de julio, debido al día de la independencia. --Existe un incremento de pasajeros en el periodo del 15 de diciembre al 1 de enero, posiblemente debido a las fiestas decembrinas.

In [8]: *#La siguiente ejecución genera una gráfica temporal del número total de pasajeros, agr*

```
df_horas_dia["dia_de_la_semana"] = df_horas_dia["pickup_datetime"].dt.dayofweek
dias_semana = df_horas_dia.groupby("dia_de_la_semana")
resultado_pasajeros_semana = dias_semana.passenger_count.mean()
resultado_pasajeros_semana = resultado_pasajeros_semana
resultado_pasajeros_semana = resultado_pasajeros_semana.sort_index()

resultado_pasajeros_semana.plot.line(style = "-*", color="green")
plt.ylabel("Número de pasajeros")
```

Out[8]: Text(0, 0.5, 'Número de pasajeros')




La gráfica por día de la semana muestra que:

--El día con mayor cantidad de pasajeros es el sábado, seguido del domingo. --El día con menor numero de pasajeros es el miércoles.

In [9]: *#La siguiente ejecución genera una gráfica temporal del número total de pasajeros, agr*

```
df_horas_dia["horas"] = df_horas_dia["pickup_datetime"].dt.hour
dias_horas = df_horas_dia.groupby("horas")
resultado_personas_horas = dias_horas.passenger_count.mean()
resultado_personas_horas = resultado_personas_horas
resultado_personas_horas = resultado_personas_horas.sort_index()
resultado_personas_horas.plot.line(style="-*", color="green")
plt.ylabel("Número de pasajeros")
```

Out[9]: Text(0, 0.5, 'Número de pasajeros')



La gráfica por horas del día muestra que:

- Los pasajeros aumentan a partir de las 6 de la noche
- Los pasajeros disminuyen cerca de las 3 de la mañana
- El pico mas bajo es cerca de las 6 de la mañana

```
In [10]: df_medallion_mas_viajes=df_medallion_mas_viajes
resultado_medallion= pd.DataFrame()

def convertCoords(row):
    x2,y2 = transform(Proj(init='epsg:4326'), Proj(init='epsg:3857'),row['pickup_longitude',
    return pd.Series([x2,y2])

#Empiezan los mapas:
NYC = x_range, y_range = ((-8242000,-8210000), (4965000,4990000))

plot_width  = int(750)
plot_height = int(plot_width//1.2)

def base_plot(tools='pan,wheel_zoom,reset',plot_width=plot_width, plot_height=plot_height):
    p = figure(tools=tools, plot_width=plot_width, plot_height=plot_height,
        x_range=x_range, y_range=y_range, outline_line_color=None,
        min_border=0, min_border_left=0, min_border_right=0,
        min_border_top=0, min_border_bottom=0, **plot_args)

    p.axis.visible = False
    p.xgrid.grid_line_color = None
```

```

p.ygrid.grid_line_color = None

p.add_tools(BoxZoomTool(match_aspect=True))

return p

options = dict(line_color=None, fill_color='orange', size=5)
df_medallion_mas_viajes=df_medallion_mas_viajes
resultado_medallion= pd.DataFrame()
def convertCoords(row):
    x2,y2 = transform(Proj(init='epsg:4326'), Proj(init='epsg:3857'),row['pickup_longitude', 'pickup_latitude'])
    return pd.Series([x2,y2])
df_medallion_mas_viajes[['columna_x', 'columna_y']]= df_medallion_mas_viajes.apply(convertCoords, axis=1)
df_medallion_mas_viajes['pickup_day']= df_medallion_mas_viajes['pickup_datetime'].dt.day
df_pu = df_medallion_mas_viajes[['columna_x', 'columna_y', 'pickup_day']].copy()
#Se crean dataframe para los arribos y llegadas de cada día de la semana
df_pu_0 = df_pu[df_pu.pickup_day == 0]
df_pu_1 = df_pu[df_pu.pickup_day == 1]
df_pu_2 = df_pu[df_pu.pickup_day == 2]
df_pu_3 = df_pu[df_pu.pickup_day == 3]
df_pu_4 = df_pu[df_pu.pickup_day == 4]
df_pu_5 = df_pu[df_pu.pickup_day == 5]
df_pu_6 = df_pu[df_pu.pickup_day == 6]

options1 = dict(line_color=None, fill_color='blue', size=5)
options2 = dict(line_color=None, fill_color='red', size=5)
options3 = dict(line_color=None, fill_color='yellow', size=5)
options4 = dict(line_color=None, fill_color='green', size=5)
options5 = dict(line_color=None, fill_color='purple', size=5)
options6 = dict(line_color=None, fill_color='orange', size=5)
options7 = dict(line_color=None, fill_color='pink', size=5)

output_notebook()
muestras1 = df_pu_0.sample(n=200, replace=True)
muestras2 = df_pu_1.sample(n=200, replace=True)
muestras3 = df_pu_2.sample(n=200, replace=True)
muestras4 = df_pu_3.sample(n=200, replace=True)
muestras5 = df_pu_4.sample(n=200, replace=True)
muestras6 = df_pu_5.sample(n=200, replace=True)
muestras7 = df_pu_6.sample(n=200, replace=True)

p=base_plot()
p.add_tile(STAMEN_TERRAIN)

p.triangle(x=muestras1['columna_x'], y = muestras1['columna_y'], **options1)
p.triangle(x=muestras2['columna_x'], y = muestras2['columna_y'], **options2)
p.triangle(x=muestras3['columna_x'], y = muestras3['columna_y'], **options3)
p.triangle(x=muestras4['columna_x'], y = muestras4['columna_y'], **options4)

```

```

p.triangle(x=muestras5['columna_x'], y = muestras5['columna_y'], **options5)
p.triangle(x=muestras6['columna_x'], y = muestras6['columna_y'], **options6)
p.triangle(x=muestras7['columna_x'], y = muestras7['columna_y'], **options7)

show(p)

```

```

In [11]: def convertCoords(row):
            x2,y2 = transform(Proj(init='epsg:4326'), Proj(init='epsg:3857'),row['dropoff_longitude',row['dropoff_latitude'])
            return pd.Series([x2,y2])
df_medallion_mas_viajes[['columnado_x','columnado_y']]= df_medallion_mas_viajes.apply(convertCoords,axis=1)
df_medallion_mas_viajes['dropoff_day'] = df_medallion_mas_viajes['dropoff_datetime'].dt.day
df_do = df_medallion_mas_viajes[['columnado_x','columnado_y','dropoff_day']].copy()
df_do_0 = df_do[df_do.dropoff_day == 0]
df_do_1 = df_do[df_do.dropoff_day == 1]
df_do_2 = df_do[df_do.dropoff_day == 2]
df_do_3 = df_do[df_do.dropoff_day == 3]
df_do_4 = df_do[df_do.dropoff_day == 4]
df_do_5 = df_do[df_do.dropoff_day == 5]
df_do_6 = df_do[df_do.dropoff_day == 6]
options1 = dict(line_color=None, fill_color='blue', size=5)
options2 = dict(line_color=None, fill_color='red', size=5)
options3 = dict(line_color=None, fill_color='yellow', size=5)
options4 = dict(line_color=None, fill_color='green', size=5)
options5 = dict(line_color=None, fill_color='purple', size=5)
options6 = dict(line_color=None, fill_color='orange', size=5)
options7 = dict(line_color=None, fill_color='pink', size=5)

output_notebook()
muestras8 = df_do_0.sample(n=200, replace=True)
muestras9 = df_do_1.sample(n=200, replace=True)
muestras10 = df_do_2.sample(n=200, replace=True)
muestras11 = df_do_3.sample(n=200, replace=True)
muestras12 = df_do_4.sample(n=200, replace=True)
muestras13 = df_do_5.sample(n=200, replace=True)
muestras14 = df_do_6.sample(n=200, replace=True)

p=base_plot()
p.add_tile(STAMEN_TERRAIN)

p.circle(x=muestras8['columnado_x'], y = muestras8['columnado_y'], **options1)
p.circle(x=muestras9['columnado_x'], y = muestras9['columnado_y'], **options2)
p.circle(x=muestras10['columnado_x'], y = muestras10['columnado_y'], **options3)
p.circle(x=muestras11['columnado_x'], y = muestras11['columnado_y'], **options4)
p.circle(x=muestras12['columnado_x'], y = muestras12['columnado_y'], **options5)
p.circle(x=muestras13['columnado_x'], y = muestras13['columnado_y'], **options6)
p.circle(x=muestras14['columnado_x'], y = muestras14['columnado_y'], **options7)
show(p)

```

```

In [12]: df_medallion_mas_viajes['segmento']=((df_medallion_mas_viajes['pickup_datetime'].dt.hour-df_medallion_mas_viajes['dropoff_datetime'].dt.hour).abs().div(24).round().astype(int))

```

```

#Se crean dataframe para los arribos y llegadas de cada dia de la semana
df_dh_0 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 0]
df_dh_1 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 1]
df_dh_2 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 2]
df_dh_3 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 3]
df_dh_4 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 4]
df_dh_5 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 5]

options1 = dict(line_color=None, fill_color='blue', size=5)
options2 = dict(line_color=None, fill_color='red', size=5)
options3 = dict(line_color=None, fill_color='yellow', size=5)
options4 = dict(line_color=None, fill_color='green', size=5)
options5 = dict(line_color=None, fill_color='purple', size=5)
options6 = dict(line_color=None, fill_color='orange', size=5)

output_notebook()
muestras1 = df_dh_0.sample(n=200, replace=True)
muestras2 = df_dh_1.sample(n=200, replace=True)
muestras3 = df_dh_2.sample(n=200, replace=True)
muestras4 = df_dh_3.sample(n=200, replace=True)
muestras5 = df_dh_4.sample(n=200, replace=True)
muestras6 = df_dh_5.sample(n=200, replace=True)

p=base_plot()
p.add_tile(STAMEN_TERRAIN)

p.circle(x=muestras1['columna_x'], y = muestras1['columna_y'], **options1)
p.circle(x=muestras2['columna_x'], y = muestras2['columna_y'], **options2)
p.circle(x=muestras3['columna_x'], y = muestras3['columna_y'], **options3)
p.circle(x=muestras4['columna_x'], y = muestras4['columna_y'], **options4)
p.circle(x=muestras5['columna_x'], y = muestras5['columna_y'], **options5)
p.circle(x=muestras6['columna_x'], y = muestras6['columna_y'], **options6)
show(p)

```

```

In [13]: # Se crean dataframe para los arribos y llegadas de cada dia de la semana
df_dh_6 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 0]
df_dh_7 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 1]
df_dh_8 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 2]
df_dh_9 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 3]
df_dh_10 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 4]
df_dh_11 = df_medallion_mas_viajes[df_medallion_mas_viajes.segmento == 5]

options1 = dict(line_color=None, fill_color='blue', size=5)
options2 = dict(line_color=None, fill_color='red', size=5)
options3 = dict(line_color=None, fill_color='yellow', size=5)
options4 = dict(line_color=None, fill_color='green', size=5)
options5 = dict(line_color=None, fill_color='purple', size=5)
options6 = dict(line_color=None, fill_color='orange', size=5)

```

```

output_notebook()
muestras1 = df_dh_6.sample(n=200, replace=True)
muestras2 = df_dh_7.sample(n=200, replace=True)
muestras3 = df_dh_8.sample(n=200, replace=True)
muestras4 = df_dh_9.sample(n=200, replace=True)
muestras5 = df_dh_10.sample(n=200, replace=True)
muestras6 = df_dh_11.sample(n=200, replace=True)

p=base_plot()
p.add_tile(STAMEN_TERRAIN)

p.triangle(x=muestras1['columnado_x'], y = muestras1['columnado_y'], **options1)
p.triangle(x=muestras2['columnado_x'], y = muestras2['columnado_y'], **options2)
p.triangle(x=muestras3['columnado_x'], y = muestras3['columnado_y'], **options3)
p.triangle(x=muestras4['columnado_x'], y = muestras4['columnado_y'], **options4)
p.triangle(x=muestras5['columnado_x'], y = muestras5['columnado_y'], **options5)
p.triangle(x=muestras6['columnado_x'], y = muestras6['columnado_y'], **options6)
show(p)

```